

神经退行性疾病人工智能辅助诊疗研究现状

1 研究范围与任务界定

神经退行性疾病人工智能辅助诊疗的研究目标，是将患者的临床表现、神经影像、语言行为及纵向随访信息转化为可用于筛查、诊断和管理的判断依据。本文以阿尔茨海默病及相关痴呆、帕金森病为重点，兼顾肌萎缩侧索硬化，围绕预测模型、多模态融合、大语言模型及临床转化展开叙述性综述。研究现状表明，该领域正在由单一数据分类向患者信息综合与诊疗流程支持扩展，但算法性能、诊断价值和患者获益仍需分别评价。

辅助诊疗并非单一任务。认知异常筛查主要识别需要进一步评估的人群，疾病分类判断患者所属临床类别，病因鉴别则关注症状背后的潜在疾病；病程预测估计未来变化，治疗支持还需要考虑干预证据及患者条件。不同任务所需的参考标准并不相同，不能将量表异常、临床诊断与病理标志物阳性视为可互换的标签。Xue 等将多模态痴呆模型扩展至多种病因识别，体现了研究从理想化分类任务向临床鉴别诊断的推进^[1]。

从技术路径看，相关方法包括人工特征驱动的机器学习、端到端深度学习、多模态表征学习，以及基于预训练语言模型的信息提取与生成。上述方法目前仍然并存，适用性取决于数据结构与研究目标。本文将生物标志物和药物信息作为模型输入或应用背景，重点讨论人工智能方法能够完成的任务、验证方式及证据边界。

2 基于机器学习与深度学习的辅助识别

2.1 神经影像与临床信息建模

神经影像和结构化临床信息为辅助诊断提供了不同层面的证据。模型可以利用影像衍生特征、神经心理测评结果和病史建立疾病分类器，也可以通过深度网络学习联合表征。评价这类方法时，关键问题不仅是测试集性能，还包括模型是否能够处理相互混淆的疾病，以及训练标签是否具有充分的临床依据。

Xue 等提出多模态痴呆病因鉴别模型，将人口学信息、健康史、神经系统评估和多序列 MRI 等信息纳入统一框架，并在多个独立队列中开展验证。该研究还进行了医生辅助评价，显示模型在部分场景中具有改善诊断判断的潜力。其贡献在于将阿尔茨海默病、额颞叶变性及路易体相关疾病等纳入更接近临床的鉴别框架，但仍需要前瞻性研究确认真实诊疗效用^[1]。

上述进展提示，研究任务应从“患者与健康对照是否可分”进一步转向“模型能否解决具体临床混淆”。若模型仅在特征差异较大的两组样本之间评价，其性能可能高估真实就诊场景中的可用性。因此，混合病因、共病和检查信息不完整的病例应被纳入后续验证设计。

2.2 语音行为与生理信号分析

语音、运动和生理信号为低负担筛查提供了补充路径。Yang 等利用夜间呼吸信号建立人工智能模型，探索帕金森病检测、严重程度估计及病程追踪，说明疾病相关信息可以来自常规运动检查以外的生理过程。该研究为居家监测提供了技术证据，但信号与疾病的统计关联仍需在不同人群及采集环境中验证^[2]。

Schalkamp 等利用 UK Biobank 加速度计数据，研究帕金森病确诊前的运动变化，识别出部分确诊前最长 7 年的风险信号。然而，其前驱期任务的精确率—召回率曲线下面积约为 0.07。该指标并非准确率，结果说明模型虽可优于若干比较方法，但在低患病率人群中仍面临误报与筛查效率问题。因而，“确诊前存在可识别信号”不能等同于“可以提前准确确诊”^[3]。

认知筛查领域的 SpeechCARE 融合声学、语言和人口学信息，开展英语、西班牙语及普通话条件下的建模。研究在普通话外部数据的零样本迁移中受到语言与标签混杂影响，经本地微调后性能才明显恢复。这表明算法可能学习数据来源特征，跨语言性能需要独立检验，不能仅依据训练集包含多种语言便认定具有普遍适用性^[4]。

2.3 方法评价的基本要求

上述研究的临床意义取决于模型在目标场景中的可靠性。对于同一患者的多次影像、录音或随访记录，应优先采用患者级划分，避免个体信息泄漏至测试集；特征筛

选、标准化和超参数选择也应限制在训练或开发数据内。在类别不平衡任务中，应结合敏感度、特异度、精确率—召回率指标和校准表现解释结果，而非仅报告总体准确率。

同时，应设置与数据规模相匹配的简单基线。若复杂模型的增益主要来自某一量表或单个强特征，其价值应通过消融分析明确。外部验证、时间外验证及亚组分析能够分别检验模型在机构差异、数据变化和人群差异下的稳定性，是判断研究可迁移性的关键环节。

3 多模态融合与纵向诊疗支持

3.1 多来源患者信息的联合建模

多模态融合旨在利用不同数据来源的互补性，形成较完整的患者表征。影像提供结构或功能信息，量表反映临床状态，语言和行为信号补充日常表现，病历则记录症状发展与治疗经过。多模态痴呆鉴别研究已经展示了联合利用这些信息的潜力^[4]，但性能改善并不意味着所有模态均具有独立贡献。

真实诊疗中的模态缺失通常不是完全随机的。例如，是否接受进一步影像或病理检查可能与症状严重程度、医疗资源及医生判断相关。因此，模型既要评价完整数据条件下的表现，也要检验不同检查组合、不同缺失比例和不同缺失机制下的性能。将模态数量增加视为方法先进性的充分条件，难以解释系统在资源有限环境中的实际价值。

3.2 病程预测与个体化监测

纵向预测关注患者未来的变化，而非仅识别当前状态。Yada 等提出基于隐马尔可夫模型的疾病进展分析框架，区分患者的进展路径与进展速度，并在肌萎缩侧索硬化数据上评价功能轨迹预测。研究显示，个体化速度建模能够改善部分预测指标，但改善幅度仍需结合具体指标和临床使用情境解释^[5]。

病程模型的研究设计应处理随访时间不规则、观察缺失及预测时点选择等问题。应严格区分在基线时可获得的信息与后续观察，避免将未来信息用于预测过去设定的

结局。用于辅助管理时，输出还应包含预测时间范围及不确定性，并通过研究检验其是否有助于调整随访、识别照护需求或改善试验分层。

3.3 从监测到辅助治疗

数据驱动的自我适应脑深部刺激是监测与干预连接的代表。Oehrle 等在 4 名男性帕金森病患者中开展盲法随机交叉可行性试验，利用个体化神经信号调节刺激，显示相较优化后的常规刺激具有改善症状和生活质量的潜力。但样本量决定了该研究主要提供可行性证据，不能据此推断所有患者均可获益^[6]。

自适应控制与大语言模型辅助决策属于不同技术路径。前者依据传感信号调节预定义干预参数，后者主要处理临床信息和知识。诊断模型、病程模型和语言模型的结果均不能直接替代治疗效果比较；预测病情严重程度也不等于识别某项治疗的个体获益。

4 大语言模型辅助诊疗研究

4.1 技术定位与任务分类

大语言模型（large language model, LLM）拓展了医学文本理解、知识问答和生成式交互能力。Singhal 等的研究通过医学问答基准和人工评价展示了语言模型的医学知识能力，也指出回答质量需要从事实性、推理、潜在伤害等维度评价。该研究属于通用医疗方法背景，并非神经退行性疾病诊疗效能的直接证据^[7]。

讨论 LLM 应用时，应区分生成式大模型、语言嵌入模型和其他预训练编码器。采用 Transformer 结构的分类器不一定属于 LLM；通过文本嵌入完成疾病分类，也不代表具备开放式临床推理能力。根据模型实际承担的角色，专项研究可分为语义表征、病历处理、知识检索、诊断生成和对话式信息采集等方向。

4.2 语言表征与疾病状态识别

Crawford 利用自发言语转写文本构建语言模型嵌入，并结合下游预测模型进行帕金森病识别和严重程度估计。该研究的直接贡献是验证预训练语言表征对分类与回归

任务的价值，其证据并不涉及自主问诊或治疗规划^[8]。Castelli 等进一步利用患者自由叙述探索用药状态及神经精神症状波动，说明语言表征可用于状态监测而不仅是疾病分类^[9]。

此类方法具有复用预训练表征的优势，但输出仍依赖转写质量、语言特征和数据划分方式。外语音频翻译后再分析可能改变停顿、重复和用词等疾病相关信息；文本表征也未必保留声学异常。因而，应分别评价原始音频、转写文本及联合输入的贡献，并检验跨患者、跨语言和跨任务迁移能力。

4.3 临床文本中的认知异常识别

Tian 等构建自主 LLM 工作流，从非结构化临床记录中筛查认知相关问题。研究显示，模型能够利用病历文本完成具有临床意义的线索识别，但敏感度受到记录不足等因素影响，且尚未完成外部验证。其目标是发现需要进一步评估的认知问题，并非直接确定阿尔茨海默病或其他痴呆病因^[10]。

这一方向的价值在于从分散记录中定位潜在异常，并降低人工整理信息的负担。评价时应明确原始证据范围，区分患者当前症状、既往病史、家属叙述与否定表达。模型还应正确处理症状时间、程度及信息来源，避免将“家族中存在痴呆”错误解释为患者自身诊断。

中文病历中的缩写、省略表达、跨段落指代和时间线组织，为专病信息提取提出了具体研究问题。针对这些问题，可将实体与关系抽取、患者事实保真度及结构化摘要质量作为独立目标，再评价其对下游诊断任务是否产生增益。

4.4 检索增强生成与专病知识支持

检索增强生成（retrieval-augmented generation, RAG）通过从外部知识源检索相关材料，为语言模型生成提供上下文。Lahiri 和 Hu 提出 AlzheimerRAG，围绕 PubMed 文献及相关图文信息开展检索与生成研究。该工作已发表于 Machine Learning and Knowledge Extraction，展示了专病文献支持的技术路径，但其文献问答与案例评价不能直接替代真实患者中的诊疗验证^[11]。

RAG的关键问题是检索证据能否被正确用于当前任务。文献与疾病相关，并不意味着适用于某位患者；检索结果可能存在证据等级差异、时间差异或结论冲突。因此，系统应分别评价检索召回率、材料相关性、答案事实性与引用支持度。对于诊疗支持，还需要考虑患者年龄、疾病阶段和既往情况是否满足证据适用条件。

在研究设计上，应通过无检索模型、基础检索模型和改进检索模型进行比较，确定增益来自知识覆盖、检索排序还是生成约束。引用数量不宜作为可靠性的替代指标，真正需要检验的是每一项关键结论能否由相应证据支持，以及证据不足时是否能够明确保留判断。

4.5 领域适配与多模态诊断生成

Kowshik 等提出 LUNAR，将多来源临床信息组织为患者级摘要，并通过强化学习适配一个 30 亿参数语言模型，开展认知状态分类、病因判断及生物标志物预测。研究包括外部队列和医生辅助评价，但所引用版本为 2026 年发布的预印本，主要依赖回顾性证据，尚需前瞻性验证^[12]。

这一方向体现了专病语言模型由知识问答向患者信息综合的扩展。然而，多模态输入需要明确实现方式：原始影像输入、影像特征输入与影像分析后文字摘要输入，并不具有相同的信息表达能力。模型若通过文字摘要利用影像结果，其性能同时受上游分析和摘要质量制约，不能仅因输入包含影像描述便认定具备直接影像理解能力。

生成诊断解释也增加了评价维度。诊断类别正确、解释内容完整和解释忠于患者事实，应分别测量。模型可能输出正确标签却引用错误病史，也可能生成流畅但缺乏依据的解释。因此，需要将关键事实核对、证据关联和不确定性表达纳入评价，而非只依据文本相似度评分。

4.6 对话式病史采集与智能体 workflow

Harrison 等开发 LUMEN 对话式人工智能原型，面向痴呆照护者采集旁证病史并生成供临床人员审阅的结构化摘要。该研究定位为概念验证，仍需进一步检验临床实用性、稳健性及 workflow 影响^[13]。与病历文本筛查相比，这类系统将信息来源从已有记录扩展到主动交互。

对话系统应评价关键症状覆盖率、追问合理性、事实保真度和交互负担。对患者及照护者提供的不同叙述，需要保留来源并标注分歧，不能在生成摘要时无依据地消除冲突。系统获得更多文本不一定意味着获得更多有效诊断信息，最终仍应检验其对医生判断和病史整理效率的影响。

智能体框架可以组织检索、抽取和核对等步骤，但流程复杂化本身并不证明有效性。对于多智能体系统，应与单模型及固定流程比较，评价各角色是否带来可重复的增益，同时报告工具调用错误、信息传递损失、推理时间和计算成本。

5 现有研究的不足与评价需求

5.1 任务边界与临床效用

现有研究中的疾病识别、病理预测、知识问答和治疗建议具有不同目标，不能用统一的“诊疗准确率”概括。通用医疗场景的研究已指出，语言模型在临床决策中存在需要专门评价和缓解的限制^[4]。该证据可用于构建评价框架，但对神经退行性疾病的适用性仍需专项实验确认。

研究应明确输入、输出、使用者与后续动作。认知异常筛查系统可以支持复评或转诊，鉴别诊断系统可以提供候选病因及依据，而治疗支持需要额外的干预证据。若实验仅包含疾病分类和问答，就应将结论限定在相应任务范围内。

5.2 数据代表性与跨场景泛化

跨语言迁移和外部验证是影响应用的重要问题。SpeechCARE 的语言混杂现象与认知异常 workflow 缺少外部验证，分别反映了数据分布变化和参考标准可获得性的限制^[4,10]。针对中文人群，研究需要说明数据来自普通话或方言、医院或居家环境，以及患者教育背景与疾病构成，避免将局部样本表现推广至全部人群。

此外，公开语料可能被预训练模型接触过，基准测试存在潜在污染风险。研究应报告模型版本、数据来源和时间范围，并尽可能采用独立、未公开或时间上较新的评价样本。任何数据使用均应遵循相应授权和伦理要求。

5.3 证据一致性与不确定性

LLM 辅助诊疗需要同时控制患者事实错误、知识错误和推断过度。对患者事实，应检查是否存在遗漏、否定关系颠倒及时间线错误；对医学知识，应检查引用来源与结论的一致性；对诊断推断，应区分已知事实、合理推测和仍需检查的信息。

评价体系宜同时包括任务指标与可靠性指标。前者可采用分类、抽取或预测误差指标；后者可采用事实支持率、引用正确率、关键遗漏率、合理拒答率和风险校准。对于医生辅助研究，应通过盲法评价及一致性分析检验结果，并关注辅助前后诊断质量、耗时及错误类型的变化。

5.4 系统贡献的可验证性

领域微调、RAG 和智能体可以共同构成系统，但方法贡献应落实到明确问题。例如，微调用于提高专病表达理解，检索用于提供可追溯证据，核对模块用于约束事实偏差。应通过消融实验分别验证各模块贡献，并报告复杂度增加所带来的成本。

对资源受限的研究与部署场景，小模型适配和结构化流程具有探索价值，但模型规模较小并不自动意味着性能充分或隐私得到保障。需要同时评价本地运行条件、访问控制、推理时延和任务质量，使方法选择与实际使用需求保持一致。

6 小结

神经退行性疾病人工智能辅助诊疗已形成影像与临床分类、数字信号筛查、多模态融合和纵向预测等研究路径。LLM 进一步拓展了语义表征、病历信息处理、专病知识检索、诊断生成与对话式病史采集能力，但各方向的证据成熟度并不相同。尤其需要区分专病临床研究与通用医疗基准、正式发表论文与预印本，以及离线预测性能与患者实际获益。

后续研究应围绕明确疾病与具体任务，将患者信息建模、外部证据利用和可靠性评价结合起来。通过患者级数据划分、独立验证、强基线比较及模块消融，才能判断方法增益是否稳定，并为其进入真实诊疗流程提供依据。

参考文献

- [1] XUE C, KOWSHIK S S, LTEIF D, et al. AI-based differential diagnosis of dementia etiologies on multimodal data[J]. *Nature Medicine*, 2024, 30(10): 2977-2989. DOI:10.1038/s41591-024-03118-z.
- [2] YANG Y, YUAN Y, ZHANG G, et al. Artificial intelligence-enabled detection and assessment of Parkinson's disease using nocturnal breathing signals[J]. *Nature Medicine*, 2022, 28(10): 2207-2215. DOI:10.1038/s41591-022-01932-x.
- [3] SCHALKAMP A K, PEALL K J, HARRISON N A, et al. Wearable movement-tracking data identify Parkinson's disease years before clinical diagnosis[J]. *Nature Medicine*, 2023, 29: 2048-2056. DOI:10.1038/s41591-023-02440-2.
- [4] AZADMALEKI H, HAGHBIN Y, RASHIDI S, et al. SpeechCARE: dynamic multimodal modeling for cognitive screening in diverse linguistic and speech task contexts[J]. *npj Digital Medicine*, 2025, 8(1): 677. DOI:10.1038/s41746-025-02026-x.
- [5] YADA Y, NAOKI H. Decomposing heterogeneity in disease progression speeds and pathways[J]. *npj Digital Medicine*, 2026, 9(1): 562. DOI:10.1038/s41746-026-02665-8.
- [6] OEHRN C R, CERNERA S, HAMMER L H, et al. Chronic adaptive deep brain stimulation versus conventional stimulation in Parkinson's disease: a blinded randomized feasibility trial[J]. *Nature Medicine*, 2024, 30(11): 3345-3356. DOI:10.1038/s41591-024-03196-z.
- [7] SINGHAL K, AZIZI S, TU T, et al. Large language models encode clinical knowledge[J]. *Nature*, 2023, 620(7972): 172-180. DOI:10.1038/s41586-023-06291-2.
- [8] CRAWFORD J L. Linguistic changes in spontaneous speech for detecting Parkinson's disease using large language models[J]. *PLOS Digital Health*, 2025, 4(2): e0000757. DOI:10.1371/journal.pdig.0000757.
- [9] CASTELLI M, SOUSA M, VOJTECH I, et al. Detecting neuropsychiatric fluctuations in Parkinson's Disease using patients' own words: the potential of large language models[J]. *npj Parkinson's Disease*, 2025, 11(1): 79. DOI:10.1038/s41531-025-00939-8.
- [10] TIAN J, FARD P, CAGAN C, et al. An autonomous agentic workflow for clinical detection of cognitive concerns using large language models[J]. *npj Digital Medicine*, 2026, 9(1): 51. DOI:10.1038/s41746-025-02324-4.
- [11] LAHIRI A K, HU Q V. AlzheimerRAG: multimodal retrieval-augmented generation for clinical use cases[J]. *Machine Learning and Knowledge Extraction*, 2025, 7(3): 89. DOI:10.3390/make7030089.
- [12] KOWSHIK S S, JASODANAND V H, BELLITTI M, et al. Domain-adapted language model using reinforcement learning for various dementias[PP/OL]. *medRxiv* (2026-03-23)[2026-09-14]. <https://www.medrxiv.org/content/10.64898/2026.03.17.26348154v1>. DOI:10.64898/2026.03.17.26348154.
- [13] HARRISON J R, ROBERTSON A, TANG S L, et al. Automating collateral histories in dementia: development and proof-of-concept evaluation of the LUMEN conversational AI[J/OL]. *International Psychogeriatrics*, 2026: 100221[2026-09-14]. <https://doi.org/10.1016/j.inpsyc.2026.100221>. DOI:10.1016/j.inpsyc.2026.100221.
- [14] HAGER P, JUNGSMANN F, HOLLAND R, et al. Evaluation and mitigation of the limitations of large language models in clinical decision-making[J]. *Nature Medicine*, 2024, 30(9): 2613-2622. DOI:10.1038/s41591-024-03097-1.